LAPORAN TUGAS PRAKTIKUM 4
Mata Kuliah Data Mining

Analisis Pola Transaksi Belanja Ritel Menggunakan Association Rule Mining Berbasis Algoritma FP-Growth

Muhammad Dzaky Haidar (NRP 5054251039)

ABSTRAK

Analisis aturan asosiasi (*association rule mining*) digunakan untuk mengekstraksi pola kecenderungan transaksi pembelian produk secara bersamaan pada data ritel berskala besar. Praktikum ini menggunakan dataset *Online Retail* (UCI Machine Learning Repository) yang memuat transaksi ritel berbasis invoice di Inggris. Data mentah sebanyak 541.909 baris dibersihkan dengan mengeliminasi transaksi batal, nilai deskripsi kosong, serta kuantitas non-positif sehingga diperoleh 530.693 transaksi valid yang terbagi ke dalam 20.136 invoice unik dan 4.065 jenis produk. Mengingat tingginya dimensionalitas transaksi, algoritma FP-Growth (*Frequent Pattern Growth*) diterapkan dengan ambang batas minimum *support* 0,01 dan minimum *confidence* 0,5. Aturan asosiasi dievaluasi berdasarkan nilai *support*, *confidence*, dan *lift*. Tiga aturan asosiasi terbaik menunjukkan keterkaitan komplementer yang sangat kuat antarsesama varian penanda tanaman herba (*Herb Marker*), dengan nilai *lift* mencapai 80,22 dan *confidence* hingga 94,42%, yang membuktikan relevansi tinggi untuk strategi *bundling* dan optimasi penataan katalog ritel.

Kata kunci: *association rule*, FP-Growth, *market basket analysis*, *support*, *confidence*, *lift*, ritel online.

1 PENDAHULUAN

Association Rule Mining merupakan salah satu metode dasar dalam data mining yang bertujuan mengidentifikasi hubungan keterkaitan atau korelasi antaritem dalam kumpulan transaksi (*market basket analysis*). Pengetahuan mengenai pola pembelian bersama (*co-occurrence*) memberikan keunggulan kompetitif bagi penyedia ritel untuk merancang strategi promosi paket hemat (*bundling*), penataan tata letak produk, serta mesin rekomendasi otomatis.

Tantangan utama pada data transaksi dunia nyata adalah ukuran dataset yang besar dan tingkat kelangkaan (*sparsity*) matriks transaksi. Algoritma Apriori konvensional menghadapi hambatan komputasi karena pembuatan *candidate itemset* berulang kali. Oleh sebab itu, praktikum ini menerapkan algoritma FP-Growth yang memetakan transaksi ke dalam struktur pohon kompak (*FP-Tree*) guna mengekstraksi *frequent itemset* secara efisien, dilanjutkan dengan pembentukan serta evaluasi aturan asosiasi.

2 METODOLOGI

2.1 Deskripsi Dataset dan Praproses Data

Dataset yang dianalisis adalah *Online Retail* dari UCI Machine Learning Repository, mencakup periode transaksi Desember 2010 hingga Desember 2011. Dataset memiliki 8 atribut: `InvoiceNo`, `StockCode`, `Description`, `Quantity`, `InvoiceDate`, `UnitPrice`, `CustomerID`, dan `Country`.

Untuk memastikan kualitas analisis asosiasi, tahap pembersihan dilakukan sebagai berikut:

1. Menghapus entri dengan `Description` kosong atau bertipe `NaN`.
2. Mengeliminasi transaksi yang dibatalkan, yaitu nomor faktur (`InvoiceNo`) yang diawali huruf `"C"`.

3. Mengeliminasi pencatatan dengan kuantitas barang non-positif (`Quantity <= 0`), yang biasanya berupa penyesuaian inventaris atau retur barang.

Perbandingan dimensi data sebelum dan setelah pembersihan dirangkum pada Tabel 1.

Tabel 1. Perbandingan jumlah baris dan transaksi sebelum dan sesudah tahap pembersihan.

Tahap Data	Jumlah Baris	Jumlah Invoice Unik
Sebelum Pembersihan (Mentah)	541.909	25.900
Setelah Pembersihan	530.693	20.136

2.2 Transformasi Data Transaksi

Data hasil pembersihan diagregasi berbasis faktur (`InvoiceNo`) dan nama item (`Description`) untuk membentuk matriks keranjang belanja (*one-hot encoded basket*). Nilai biner menandakan keberadaan produk dalam transaksi:

$$B_{i,j} = \begin{cases} 1 & \text{jika transaksi } i \text{ memuat produk } j \\ 0 & \text{lainnya} \end{cases} \tag{1}$$

Transformasi ini menghasilkan matriks berukuran 20.136×4.065, mencerminkan 20.136 transaksi keranjang belanja dan 4.065 jenis produk unik.

2.3 Metrik Evaluasi Aturan Asosiasi

Aturan asosiasi dinyatakan dalam bentuk implikasi $X \rightarrow Y$, di mana X merepresentasikan anteseden (*antecedent*) dan Y merepresentasikan konsekuen (*consequent*). Tiga metrik utama yang digunakan adalah:

1. ***Support*:** Proporsi transaksi dalam dataset yang memuat itemset $X \cup Y$:

$$\text{Support}(X \rightarrow Y) = P(X \cup Y) = \frac{\sigma(X \cup Y)}{N} \tag{2}$$

2. ***Confidence*:** Probabilitas bersyarat transaksi memuat Y dengan syarat memuat X:

$$\text{Confidence}(X \rightarrow Y) = P(Y \mid X) = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)} \tag{3}$$

3. ***Lift*:** Rasio observasi kemunculan bersama terhadap ekspektasi independen antara X dan Y:

$$\text{Lift}(X \rightarrow Y) = \frac{P(X \cup Y)}{P(X) \cdot P(Y)} = \frac{\text{Confidence}(X \rightarrow Y)}{\text{Support}(Y)} \tag{4}$$

Nilai $\text{Lift} > 1$ mengindikasikan bahwa keberadaan item X meningkatkan probabilitas kemunculan item Y secara signifikan di atas ekspektasi kebetulan acak.

3 HASIL DAN PEMBAHASAN

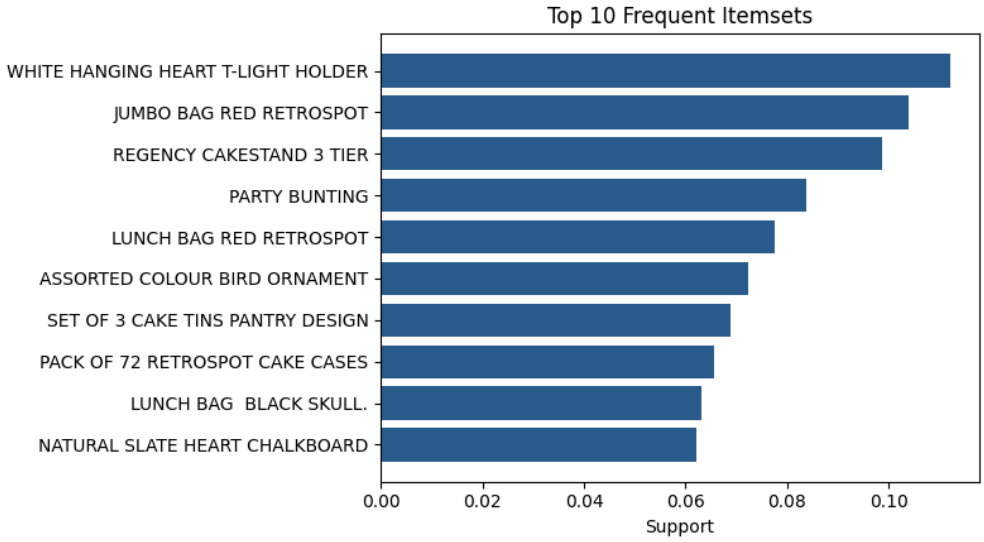
3.1 Pola Itemset Frekuen Teratas

Pengujian awal menggunakan parameter minimum *support* bernilai 0,01 (1% dari seluruh transaksi). Dengan parameter tersebut, algoritma FP-Growth mengekstraksi seluruh kombinasi itemset yang memenuhi ambang batas frekuensi kemunculan. Sepuluh item tunggal dengan nilai *support* tertinggi disajikan pada Tabel 2.

Tabel 2. Sepuluh itemset frekuen tunggal teratas berdasarkan nilai *support*.

No.	Deskripsi Itemset	*Support*
1	WHITE HANGING HEART T-LIGHT HOLDER	0,1122
2	JUMBO BAG RED RETROSPOT	0,1039
3	REGENCY CAKESTAND 3 TIER	0,0988
4	PARTY BUNTING	0,0837
5	LUNCH BAG RED RETROSPOT	0,0777
6	ASSORTED COLOUR BIRD ORNAMENT	0,0723
7	SET OF 3 CAKE TINS PANTRY DESIGN	0,0688
8	PACK OF 72 RETROSPOT CAKE CASES	0,0656
9	LUNCH BAG BLACK SKULL	0,0632
10	NATURAL SLATE HEART CHALKBOARD	0,0620

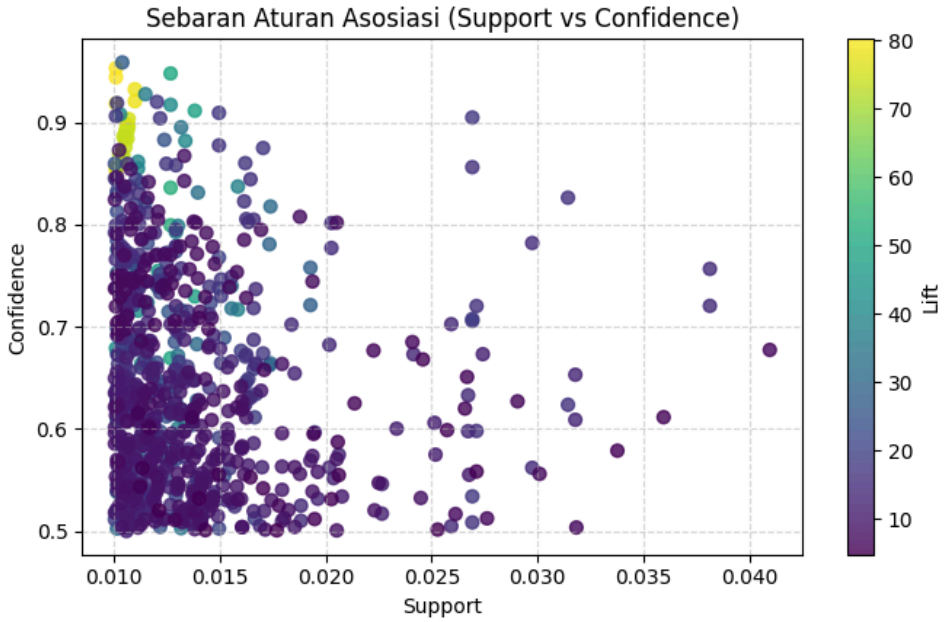
Item **WHITE HANGING HEART T-LIGHT HOLDER** merupakan produk paling populer dengan *support* sebesar 11,22% (terdapat pada lebih dari 2.259 transaksi), disusul oleh berbagai perlengkapan dekorasi dan tas belanja berseri (*Retrospot*). Visualisasi sepuluh itemset teratas disajikan pada Gambar 1.



Gambar 1. Sepuluh itemset frekuen teratas berdasarkan nilai *support*.

3.2 Evaluasi Tiga Aturan Asosiasi Terbaik

Aturan asosiasi disaring dengan kriteria ambang batas minimum *confidence* sebesar 0,5 (50%), lalu diurutkan berdasarkan kekuatan keterikatan asosiasi (***Lift***) tertinggi. Sebaran aturan yang diperoleh berdasarkan metrik *support*, *confidence*, dan *lift* divisualisasikan pada Gambar 2.



Gambar 2. Sebaran aturan asosiasi (*support* vs *confidence*) dengan gradien warna merepresentasikan nilai *lift*.

Tiga aturan asosiasi terbaik yang diperoleh disajikan pada Tabel 3.

Tabel 3. Tiga aturan asosiasi terbaik yang diurutkan berdasarkan nilai *lift* tertinggi.

No.	Anteseden (X)	Konsekuen (Y)	*Support*	*Conf.*	*Lift*
1	HERB MARKER THYME	HERB MARKER ROSEMARY, HERB MARKER PARSLEY	0,0101	0,8565	**80,22**
2	HERB MARKER ROSEMARY, HERB MARKER PARSLEY	HERB MARKER THYME	0,0101	**0,9442**	**80,22**
3	HERB MARKER ROSEMARY	HERB MARKER THYME, HERB MARKER PARSLEY	0,0101	0,8458	79,96

3.3 Interpretasi Bisnis Ritel

Berdasarkan hasil pengujian pada Tabel 3, pola asosiasi didominasi oleh set produk penanda herba kebun (**Herb Marker**):

1. **Aturan 1 & Aturan 2 (Aturan Resiprokal, Lift = 80,22):** Pembelian penanda herba jenis *Thyme* memiliki hubungan timbal balik yang sangat kuat dengan pembelian varian *Rosemary* dan *Parsley*. Nilai *confidence* aturan kedua mencapai 94,42%, yang berarti jika seorang pelanggan membeli penanda *Rosemary* dan *Parsley*, kemungkinan mereka juga membeli penanda *Thyme* adalah sebesar 94,42%. Nilai *lift* sebesar 80,22 menegaskan bahwa probabilitas pembelian bersama ini 80 kali lebih tinggi dibandingkan probabilitas jika produk dibeli secara terpisah tanpa korelasi.
2. **Aturan 3 (Lift = 79,96, Confidence = 84,58%):** Pelanggan yang membeli penanda herba *Rosemary* memiliki kecenderungan sebesar 84,58% untuk melengkapi koleksi mereka dengan varian *Thyme* dan *Parsley*. Pola ini mengonfirmasi perilaku konsumen ritel berkebun yang cenderung membeli perlengkapan dalam satu paket koleksi lengkap untuk kebun dapur mereka.

3.4 Implikasi Strategis terhadap Operasional Ritel

Temuan di atas memberikan rekomendasi aksi praktis bagi manajemen ritel:

1. ***Product Bundling*:** Pihak toko dapat merancang paket penjualan terpadu (*"Garden Herb Marker Set"*) yang menggabungkan varian *Thyme*, *Rosemary*, dan *Parsley* dengan sedikit potongan harga daripada penjualan satuan. Hal ini mempercepat perputaran inventaris barang.
2. ***Cross-Selling & Recommendation Engine*:** Pada platform e-commerce, saat pelanggan memasukkan salah satu varian penanda herba ke dalam keranjang, sistem dapat secara otomatis menyarankan varian lainnya melalui widget *"Frequently Bought Together"*.
3. ***Placement Strategy*:** Untuk toko fisik, produk-produk dengan *lift* tinggi tersebut wajib diletakkan pada rak yang sama secara berdampingan guna memudahkan navigasi belanja pelanggan.

4 KESIMPULAN

Berdasarkan hasil praktikum *association rule mining* pada dataset *Online Retail*:

1. Tahap pembersihan data berhasil mereduksi transaksi tidak valid dan menyisakan 20.136 transaksi faktur bersih serta 4.065 jenis produk unik.
2. Algoritma FP-Growth terbukti efisien dalam memproses dataset transaksi bervolume besar tanpa menimbulkan kendala memori berlebih.
3. Pengaturan minimum *support* 0,01 dan minimum *confidence* 0,5 mampu mengekstraksi aturan asosiasi yang sangat spesifik dan bermakna. Tiga aturan terbaik didominasi oleh lini produk *Herb Marker* dengan nilai *lift* mencapai lebih dari 80 kali lipat dan *confidence* di atas 84%, memberikan landasan data yang kuat untuk perancangan strategi *bundling* dan rekomendasi ritel.