LAPORAN TUGAS PRAKTIKUM 3
Mata Kuliah Data Mining

Klasifikasi Deteksi Penipuan Kartu Kredit pada Data Tidak Seimbang Menggunakan Ensemble Method dan Teknik Resampling

Muhammad Dzaky Haidar (NRP 5054251039)

ABSTRAK

Dataset *Credit Card Fraud Detection* sangat tidak seimbang: hanya 492 dari 284.807 transaksi (0,1727%) adalah penipuan. Laporan ini membandingkan *Random Forest* tanpa resampling, *Random Forest* dengan SMOTE, dan *ensembled boosting* (XGBoost dan LightGBM) yang di *train* nya pada subset seimbang hasil *undersampling* dan SMOTE, dengan threshold 0,5 maupun threshold yang disetel pada data validasi. Resampling hanya dilakukan pada *Training Data* (split 80:20 *stratified*). Pada *Testing Data*, *ensembled boosting* mencapai AUC-ROC tertinggi (0,9852) dibandingkan *Random Forest* (0,9510) dan RF + SMOTE (0,9744). threshold 0,5 menghasilkan *recall* 0,8571 tetapi *precision* hanya 0,3700; penyetelan threshold memulihkan *precision* menjadi 0,8953 (F_1 = 0,8370). Akurasi tidak memadai sebagai metrik pada data ini.

Kata kunci: deteksi penipuan, ketidakseimbangan kelas, *Random Forest*, XGBoost, LightGBM, SMOTE.

1 PENDAHULUAN

Deteksi penipuan kartu kredit merupakan *Binary Classification* dengan kelas minoritas yang sangat langka sehingga algoritma standar cenderung bias ke kelas mayoritas (Dal Pozzolo et al., 2014; He & Garcia, 2009). Praktikum ini menerapkan *ensemble method*, yaitu *Random Forest* (Breiman, 2001) serta *gradient boosting* (XGBoost (Chen & Guestrin, 2016) dan LightGBM (Ke et al., 2017)), dan membandingkan performanya tanpa dan dengan penanganan *class imbalance* pada dataset Kaggle (Machine Learning Group – ULB, 2018). Fokus laporan adalah metodologi dan hasil evaluasi pada kelas *fraud*.

2 METODOLOGI

2.1 Data dan Praproses

Dataset memuat 284.807 transaksi dengan 31 kolom tanpa nilai hilang: `Time`, `V1`–`V28` (komponen PCA anonim), `Amount`, dan label `Class` (0 = normal, 1 = *fraud*). Data dibagi 80:20 secara *stratified* (`stratify=y`, `random_state=3407`). Seluruh fitur dipakai tanpa *Scaling* karena model berbasis *Tree* tidak sensitif terhadap skala. *Resampling* hanya diterapkan pada *Training Data* dan *Testing Data* dipertahankan pada distribusi aslinya.

2.2 Skenario Pemodelan

Empat skenario dibandingkan (Tabel 1). Pada skenario 3 dan 4, tiap iterasi ($i = 1, ..., 10$) meng-*undersample* kelas normal secara acak hingga rasio 0,1 terhadap *fraud* lalu meng-*oversample* kelas *fraud* dengan SMOTE hingga rasio 0,5, mengikuti gagasan *exploratory undersampling* (Liu et al., 2009). SMOTE membangkitkan sampel sintetis melalui interpolasi (Chawla et al., 2002):

$$\boldsymbol{x}_{\text{baru}} = \boldsymbol{x}_i + \lambda(\boldsymbol{x}_{\text{nn}} - \boldsymbol{x}_i), \quad \lambda \sim \mathcal{U}(0,1). \tag{1}$$

Pada setiap iterasi di *train* nya satu XGBoost dan satu LightGBM sehingga diperoleh 20 model, dan probabilitas akhir adalah rata-rata keluaran semua model (Persamaan 2). Karena resampling menggeser probabilitas prior, threshold pada skenario 4 dipilih dengan memaksimalkan F_1 pada data validasi (20% *Training Data*) menurut Persamaan 3, tanpa menyentuh *Testing Data* (Dal Pozzolo et al., 2015).

$$\hat{p}(y = 1 \mid \boldsymbol{x}) = \frac{1}{M} \sum_{m=1}^{M} p_m(y = 1 \mid \boldsymbol{x}), \quad M = 20. \tag{2}$$

$$t^* = \arg\max_t F_1(t). \tag{3}$$

Tabel 1. Skenario eksperimen. Pustaka: *scikit-learn* (Pedregosa et al., 2011) dan *imbalanced-learn* (Lemaître et al., 2017).

No.	Model dan penanganan *imbalance*	threshold
1	*Random Forest* (`n_estimators=200`), tanpa resampling	0,5
2	*Random Forest* (200 *Tree*) + SMOTE (rasio 0,1)	0,5
3	*ensembled* XGBoost + LightGBM (masing-masing 300 *Tree*, `learning_rate=0,05`); *undersampling* 0,1 + SMOTE 0,5; 10 iterasi	0,5
4	Seperti skenario 3, di *train* nya pada 80% *Training Data*; threshold disetel pada validasi	0,9856

2.3 Metrik Evaluasi

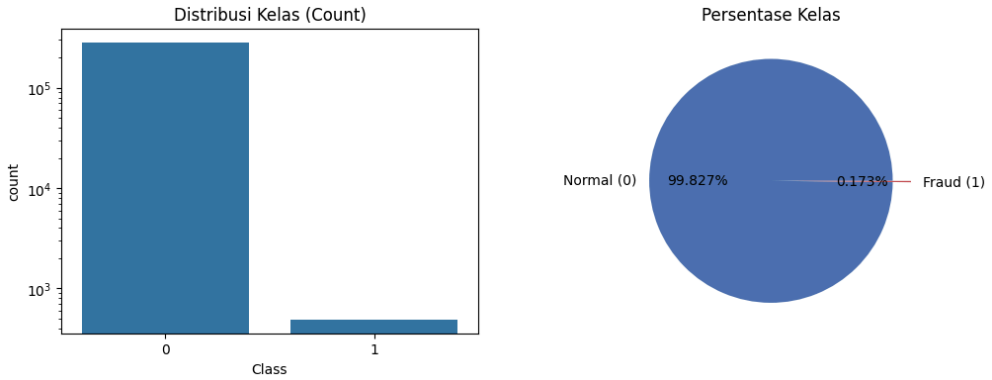
Dengan *fraud* sebagai kelas positif, evaluasi memakai *precision*, *recall*, F_1, dan AUC-ROC pada *Testing Data*, serta *confusion matrix*:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{4}$$

3 HASIL DAN PEMBAHASAN

3.1 Distribusi Kelas

Dataset memuat 284.315 transaksi normal (99,8273%) dan 492 *fraud* (0,1727%), atau rasio sekitar 578:1 (Gambar 1). Pembagian *stratified* menghasilkan 227.845 *Training Data* (394 *fraud*) dan 56.962 *Testing Data* (98 *fraud*). SMOTE pada skenario 2 menghasilkan 227.451 normal dan 22.745 *fraud*; setiap iterasi *ensembled* di *train* nya pada 3.940 normal dan 1.970 *fraud*.



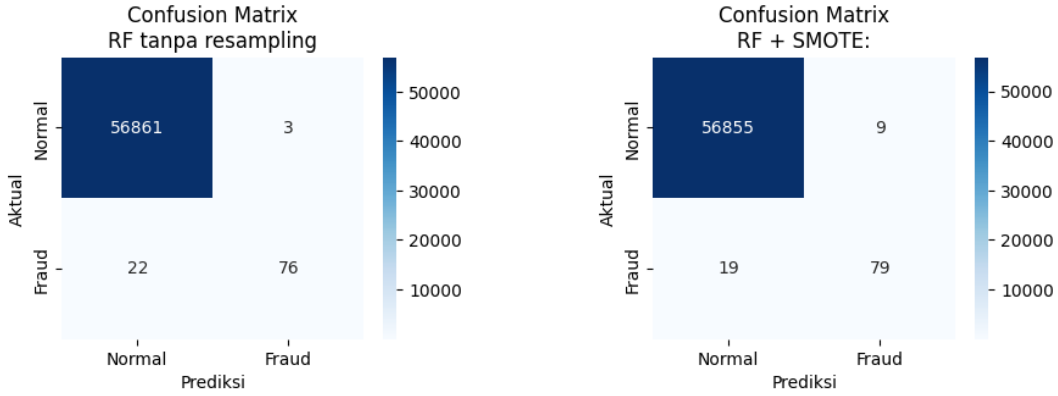
Gambar 1. Distribusi kelas pada atribut `Class` (jumlah dengan skala logaritmik dan persentase).

3.2 Performa Model

Tabel 2 merangkum hasil pada *Testing Data* dan Gambar 2 menampilkan *confusion matrix* keempat model.

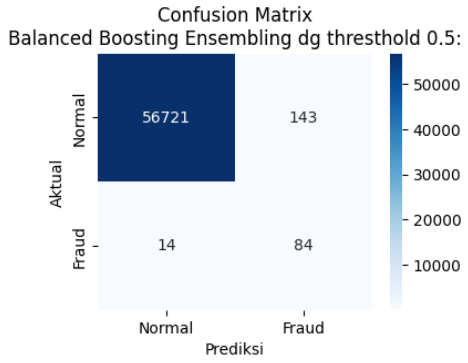
Tabel 2. Metrik pada *Testing Data* (98 *fraud*, 56.864 normal); nilai terbaik per kolom dicetak tebal. FP dan FN diturunkan dari *precision* dan *recall*.

Model	Prec.	Recall	F_1	AUC-ROC	FP	FN
1. RF tanpa resampling	**0,9620**	0,7755	**0,8588**	0,9510	3	22
2. RF + SMOTE	0,8977	0,8061	0,8495	0,9744	9	19
3. *ensembled* (threshold 0,5)	0,3700	**0,8571**	0,5169	**0,9855**	143	14
4. *ensembled* (threshold disetel)	0,8953	0,7857	0,8370	0,9852	9	21

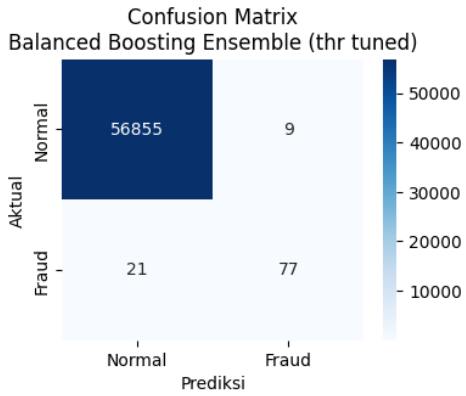


(a) RF tanpa resampling

(b) RF + SMOTE



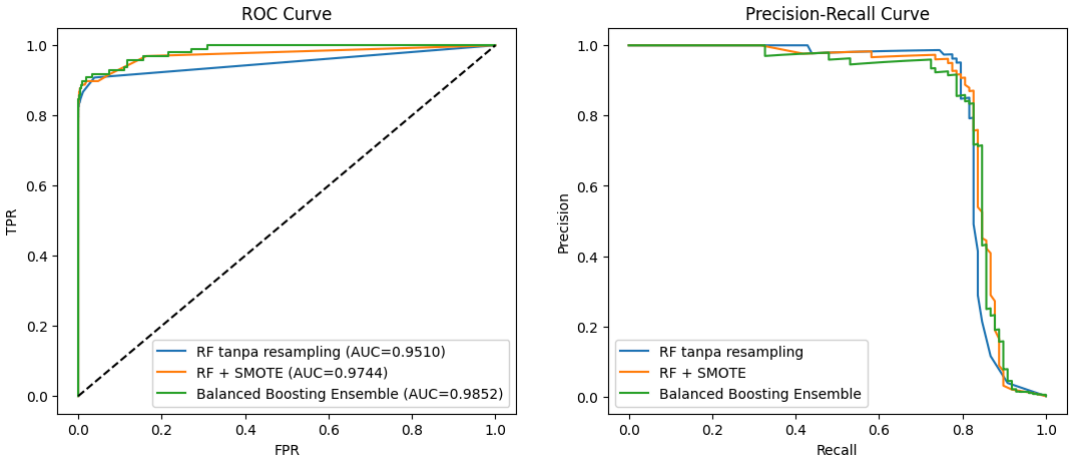
(c) *ensembled*, threshold 0,5



(d) *ensembled*, threshold disetel

Gambar 2. *Confusion matrix* keempat model pada *Testing Data*.

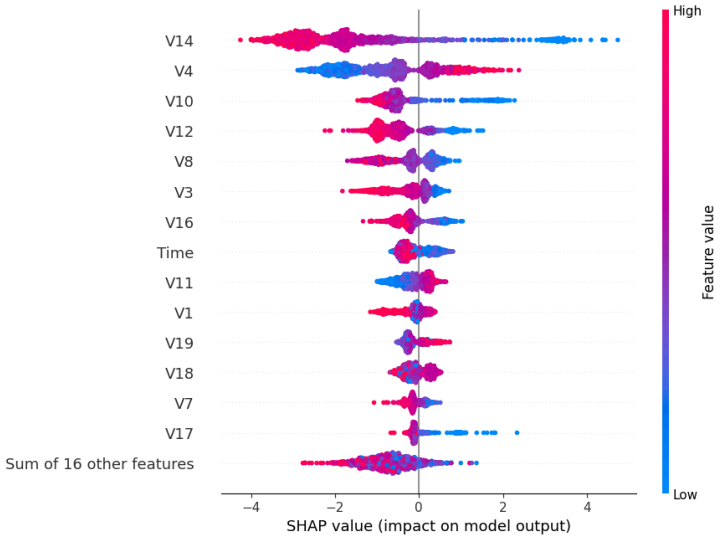
Resampling meningkatkan kualitas pemisahan kelas: AUC-ROC naik dari 0,9510 (RF) menjadi 0,9744 (RF + SMOTE) dan 0,9852 (*ensembled*). *ensembled* pada threshold 0,5 mendeteksi 84 dari 98 *fraud* tetapi menghasilkan 143 positif palsu (F_1 = 0,5169), karena subset *train* nya memuat 33% *fraud* sehingga probabilitas keluaran terlalu tinggi. Penyetelan threshold ke 0,9856 menekan positif palsu menjadi 9 dan menaikkan F_1 menjadi 0,8370, sehingga pemilihan threshold berdampak lebih besar daripada pemilihan model. Pada satu threshold tetap, F_1 *Random Forest baseline* (0,8588) sedikit lebih tinggi; namun selisihnya hanya beberapa transaksi dari 98 *fraud* sehingga tidak cukup untuk menyimpulkan keunggulan yang signifikan. Keunggulan *ensembled* tampak konsisten pada AUC-ROC dan pada daerah *recall* tinggi di kurva *Precision-Recall* (Gambar 3), yang lebih informatif pada data tidak seimbang (Saito & Rehmsmeier, 2015).



Gambar 3. Kurva ROC (kiri) dan *Precision-Recall* (kanan) pada *Testing Data*.

3.3 Interpretasi SHAP

Beeswarm plot SHAP (Lundberg & Lee, 2017) pada satu model XGBoost *ensembled* (Gambar 4; dihitung pada 98 *fraud* uji dan 1.500 normal acak) menunjukkan fitur `V14`, `V4`, `V10`, dan `V12` paling berpengaruh. Nilai `V14`, `V10`, dan `V12` yang rendah mendorong prediksi ke arah *fraud*, sedangkan nilai `V4` yang tinggi mendorong ke arah *fraud*. Karena fitur adalah komponen PCA anonim, interpretasi bersifat statistik, bukan semantik.



Gambar 4. *Beeswarm plot* SHAP untuk satu model XGBoost pada *ensembled* (positif = mendorong prediksi ke *fraud*; merah = nilai fitur tinggi).

3.4 Mengapa Akurasi Tidak Cukup

Pengklasifikasi yang selalu memprediksi "normal" mencapai akurasi $\frac{56.864}{56.962} \approx 99,83\%$ pada *Testing Data* namun *recall* nol. Akurasi keempat model hampir sama (0,9972–0,9996), padahal F_1 mereka berkisar 0,5169–0,8588; skenario 3 misalnya berakurasi 0,9972 tetapi hanya sekitar 37 dari 100 peringatan *fraud*-nya yang benar. Karena itu evaluasi harus bertumpu pada *precision*, *recall*, F_1, AUC-ROC, dan *confusion matrix* kelas minoritas.

4 KESIMPULAN

1. Dataset sangat timpang (rasio sekitar 578:1), sehingga diperlukan split *stratified*, resampling hanya pada *Training Data*, dan metrik pada kelas minoritas.

2. Resampling dengan ensemble menaikkan AUC-ROC dari 0,9510 menjadi 0,9852; threshold 0,5 pada data hasil resampling menurunkan *precision* (0,3700), dan penyetelan threshold pada data validasi memulihkannya (0,8953; F_1 = 0,8370).
3. Perbedaan F_1 antarmodel pada satu threshold kecil dan dievaluasi hanya pada satu split dengan 98 *fraud*; validasi silang berulang disarankan untuk penelitian lanjutan.

DAFTAR PUSTAKA

Breiman, L. (2001). Random Forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Dal Pozzolo, A., Caelen, O., Johnson, R. A., & Bontempi, G. (2015). Calibrating Probability with Undersampling for Unbalanced Classification. *2015 IEEE Symposium Series on Computational Intelligence (SSCI)*, 159–166. https://doi.org/10.1109/SSCI.2015.33

Dal Pozzolo, A., Caelen, O., Le Borgne, Y.-A., Waterschoot, S., & Bontempi, G. (2014). Learned Lessons in Credit Card Fraud Detection from a Practitioner Perspective. *Expert Systems with Applications*, *41*(10), 4915–4928. https://doi.org/10.1016/j.eswa.2014.02.026

He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*, *21*(9), 1263–1284. https://doi.org/10.1109/TKDE.2008.239

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 3146–3154.

Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. *Journal of Machine Learning Research*, *18*(17), 1–5.

Liu, X.-Y., Wu, J., & Zhou, Z.-H. (2009). Exploratory Undersampling for Class-Imbalance Learning. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, *39*(2), 539–550. https://doi.org/10.1109/TSMCB.2008.2007853

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 4765–4774.

Machine Learning Group – ULB. (2018,). *Credit Card Fraud Detection*. https://www.kaggle.com/mlg-ulb/creditcardfraud

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, *10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432