

Tugas 2 - Tipe Data, Preprocessing, dan Pengukuran Jarak

1. Muhammad Fasya Atthaya Rosyada – 5054251006
2. Muhammad Dzaky Haidar - 5054251039

1. PPT

1. Tipe Data (Data Types)

- Data merupakan kumpulan dari objek data dan atribut-atributnya. Atribut (juga dikenal sebagai variabel atau fitur) adalah properti atau karakteristik dari sebuah objek.
- Tipe-tipe atribut terbagi menjadi empat jenis utama:
 - **Nominal:** Atribut yang nilainya hanya berfungsi untuk membedakan objek, seperti kode pos, nomor ID, atau warna mata.
 - **Ordinal:** Atribut yang nilainya dapat mengurutkan objek, seperti peringkat nilai (grade) atau tingkat ketinggian {tinggi, sedang, pendek}.
 - **Interval:** Atribut di mana selisih/perbedaan antar nilai memiliki makna, contohnya tanggal kalender atau suhu dalam skala Celcius maupun Fahrenheit.
 - **Ratio:** Atribut di mana perbedaan sekaligus rasio antar nilainya bermakna, contohnya panjang, waktu, atau suhu dalam skala Kelvin.
- Atribut juga dapat diklasifikasikan sebagai atribut diskrit (memiliki himpunan nilai terbatas/dapat dihitung, seperti jumlah kata) dan atribut kontinu (berupa bilangan real, seperti tinggi atau berat badan).
- Jenis-jenis dataset meliputi data record (seperti matriks data, data dokumen, dan data transaksi), data graf (seperti struktur molekul atau *World Wide Web*), dan data terurut (seperti data spasial, temporal, atau sekuens genetik).

2. Pengukuran Jarak dan Kemiripan (Similarity and Distance)

- **Similarity (Kemiripan):** Ukuran numerik tentang seberapa mirip dua objek data, di mana nilainya akan semakin tinggi jika objek semakin mirip (sering kali berada di rentang $[0,1]$).
- **Dissimilarity (Ketidakmiripan/Jarak):** Ukuran numerik tentang seberapa berbeda dua objek data, di mana nilainya akan semakin rendah jika objek semakin mirip (batas minimum ketidakmiripan biasanya adalah 0).
- Beberapa metode pengukuran jarak dan kemiripan yang umum digunakan meliputi:
 - **Jarak Euclidean:** Menghitung jarak garis lurus antara dua titik data berdasarkan atribut-atributnya.
 - **Jarak Minkowski:** Bentuk generalisasi dari jarak Euclidean; di dalamnya terdapat jarak *City block/Manhattan* (jika $r=1$), jarak Euclidean (jika $r=2$), dan jarak *supremum* (jika r mendekati tak terhingga).
 - **Jarak Mahalanobis:** Menghitung jarak yang mempertimbangkan matriks kovarians data.

- **Similarity untuk Vektor Biner:** Menggunakan *Simple Matching Coefficient* (SMC) dan *Jaccard Coefficient* untuk membandingkan objek dengan atribut biner.
- **Cosine Similarity:** Digunakan untuk mengukur kemiripan antar vektor dokumen berdasarkan hasil kali titik (*dot product*) dari vektor-vektor tersebut.
- **Korelasi:** Mengukur hubungan linier antara dua objek data.

3. Preprocessing Data Data di dunia nyata sering kali memiliki masalah kualitas seperti *noise*, outlier, nilai yang hilang (*missing values*), atau data duplikat. Preprocessing dilakukan untuk mengatasi hal ini dan menyederhanakan proses analitik melalui beberapa teknik:

- **Aggregation:** Menggabungkan dua atau lebih atribut atau objek menjadi satu atribut/objek tunggal untuk mereduksi jumlah data, mengubah skala waktu/wilayah, atau menghasilkan data yang lebih stabil.
- **Sampling:** Teknik reduksi data yang sering digunakan dengan cara mengambil sampel data yang representatif (memiliki properti yang mirip dengan keseluruhan populasi), seperti melalui metode *Simple Random Sampling* atau *Stratified Sampling*.
- **Dimensionality Reduction:** Teknik untuk mengurangi jumlah atribut demi menghindari "kutukan dimensi" (*curse of dimensionality*), menghemat memori, dan menghilangkan noise, contohnya menggunakan *Principal Components Analysis* (PCA).
- **Feature Subset Selection:** Menghapus atribut/fitur yang berulang (redundan) atau tidak relevan dengan tugas *data mining* yang sedang dikerjakan.
- **Feature Creation:** Membuat atribut baru yang lebih efisien dalam merekam informasi penting dari data, misalnya melalui ekstraksi fitur, konstruksi fitur, atau pemetaan ke ruang yang baru (*Fourier* dan *wavelet transform*).
- **Discretization dan Binarization:** *Discretization* adalah proses mengubah atribut kontinu menjadi atribut ordinal yang terbagi ke dalam beberapa kategori, sementara *Binarization* memetakan atribut ke dalam bentuk variabel biner (sering digunakan dalam analisis asosiasi).
- **Attribute Transformation:** Sebuah fungsi yang memetakan sekumpulan nilai dari atribut ke sekumpulan nilai baru secara keseluruhan, contohnya melalui normalisasi atau standardisasi statistik.

2. Video

1. Skala Pengukuran Data (Scales of Measurement)

- Skala pengukuran menentukan bagaimana data dapat dikategorikan, diurutkan, dan diolah secara matematis.
- Terdapat empat jenis skala pengukuran:
 - **Nominal:** Digunakan untuk membedakan kategori tanpa urutan. Contohnya warna, jenis kelamin, kode pos, atau nomor ID. Jika menggunakan angka, angka tersebut hanya berfungsi sebagai label.
 - **Ordinal:** Data memiliki urutan atau peringkat, tetapi selisih antarperingkat tidak dapat diukur secara pasti. Contohnya tingkat kepuasan, nilai huruf, atau peringkat perlombaan.
 - **Interval:** Data memiliki urutan dan selisih yang konsisten, tetapi tidak memiliki titik nol mutlak. Contohnya suhu Celsius dan Fahrenheit. Suhu 40°C tidak berarti dua kali lebih panas daripada 20°C.
 - **Ratio:** Memiliki urutan, selisih yang konsisten, dan titik nol mutlak. Selisih maupun perbandingan rasio dapat dihitung. Contohnya tinggi, berat, usia, jarak, dan pendapatan.
- Perbedaan utama keempat skala:
Pemilihan skala pengukuran penting karena menentukan jenis analisis statistik yang dapat diterapkan pada data.

2. Euclidean Distance dan Cosine Similarity

- **Similarity** menunjukkan tingkat kemiripan dua objek. Nilai yang semakin besar berarti objek semakin mirip.
- **Dissimilarity atau distance** menunjukkan tingkat perbedaan. Nilai yang semakin kecil berarti objek semakin mirip.

3. Euclidean Distance

- Euclidean distance mengukur jarak garis lurus antara dua titik data.
- Rumusnya adalah:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- Perhitungannya dilakukan dengan mencari selisih setiap atribut, menguadratkannya, menjumlahkan seluruh hasilnya, kemudian mengambil akar kuadrat.

- Nilai jarak yang kecil menunjukkan dua objek berdekatan, sedangkan nilai yang besar menunjukkan keduanya semakin berbeda.

4. Distance Matrix

- Hasil jarak antara seluruh pasangan objek dapat disusun dalam **distance matrix**.
- Nilai diagonal matriks selalu **0** karena merupakan jarak objek dengan dirinya sendiri.
- Matriks bersifat simetris karena jarak A ke B sama dengan jarak B ke A.
- Distance matrix membantu menemukan pasangan objek yang paling dekat atau paling jauh.

5. Cosine Similarity

- Cosine similarity mengukur kemiripan berdasarkan sudut atau arah dua vektor, bukan berdasarkan besar nilainya.
- Rumusnya adalah:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

- Nilai mendekati **1** menunjukkan kemiripan tinggi, nilai mendekati **0** menunjukkan tidak mirip, dan nilai mendekati **-1** menunjukkan arah yang berlawanan.
- Metode ini banyak digunakan untuk membandingkan dokumen berdasarkan pola kemunculan kata.

6. Perbedaan Utama

- **Euclidean distance** berfokus pada jarak dan besar nilai. Semakin kecil hasilnya, semakin mirip kedua objek.
- **Cosine similarity** berfokus pada kesamaan arah atau pola. Semakin besar hasilnya, semakin mirip kedua objek.
- Euclidean distance cocok untuk data numerik dan koordinat, sedangkan cosine similarity sering digunakan dalam analisis dokumen.