

# Laporan Praktikum 1 EDA

Muhammad Dzaky Haidar  
5054251039

## 1. Deskripsi Dataset dan Metode

Praktikum ini mengeksplorasi pola publikasi dan karakteristik judul berita teknologi dari DetikINET. Data diambil langsung dari HTML halaman indeks menggunakan requests dan BeautifulSoup. Ekstraksi dilakukan melalui pagination, dibatasi pada domain inet.detik.com, dan diberi jeda dua detik antarpemintaan. ID berita digunakan untuk mencegah pencatatan berulang. Hasil mentah disimpan ke berita\_raw.csv sebelum diproses.

Proses Pengambilan berhenti pada halaman ke-81 dengan total diperoleh 1.611 berita unik dan 7 kolom awal, sehingga memenuhi syarat minimal 1.500 baris dan 5 kolom. Setelah pembentukan tanggal, jam, jumlah kata, dan jumlah karakter, dataset memiliki 11 kolom. Satu baris mewakili satu berita; kategori diperoleh dari websitenya.

| Kelompok Atribut                 | Tipe dan Makna                                                                                         |
|----------------------------------|--------------------------------------------------------------------------------------------------------|
| id_berita, kategori, url, gambar | Nominal: pengenal atau label yang tidak memiliki urutan peringkat.                                     |
| judul                            | Nominal berupa teks bebas: judul berita yang tidak memiliki urutan peringkat.                          |
| timestamp, waktu_teks, tanggal   | Temporal berskala interval: menyatakan waktu publikasi; dapat diurutkan dan selisih waktunya bermakna. |
| jam                              | Numerik diskrit, siklik: jam publikasi berupa bilangan bulat 0–23 yang berulang setiap hari.           |
| jumlah_kata, jumlah_karakter     | Numerik diskrit: jumlah kata dan karakter dalam judul, berupa bilangan bulat.                          |

## 2. Statistik Deskriptif

| Atribut         | Mean  | Median | Modus | Std. Dev | Min-Max | Q1-Q3 |
|-----------------|-------|--------|-------|----------|---------|-------|
| Jumlah Kata     | 9,93  | 10     | 9     | 1,63     | 3-16    | 9-11  |
| Jumlah Karakter | 62,52 | 63     | 64    | 8,40     | 18-84   | 57-68 |

Kedua atribut memiliki 1.611 nilai tersedia. Separuh data bagian tengah berada pada 9-11 kata dan 57-68 karakter. Mean dan median berdekatan, tetapi kesamaan ini belum cukup untuk menyimpulkan distribusi normal.

## 3. Kualitas dan Penanganan Data


Terdapat 1 nilai kosong pada gambar (0,06%); enam kolom awal lainnya lengkap. Duplikat baris maupun ID berjumlah nol. Pembersihan mencakup pemeriksaan ulang duplikasi, penghapusan spasi tepi judul, penandaan judul kosong, serta konversi timestamp. URL gambar kosong tidak diimputasi dan barisnya dipertahankan karena tidak mengganggu analisis judul.

Dari kuartil, IQR jumlah kata = 2 sehingga batas outlier global adalah  $<6$  atau  $>14$  kata. IQR karakter = 11 sehingga batasnya  $<40,5$  atau  $>84,5$  karakter. Minimum dan maksimum menunjukkan adanya judul ekstrem, tetapi jumlah outlier belum tercatat pada notebook. Nilai ekstrem dipertahankan; judul yang sangat pendek atau panjang belum tentu salah.

# Laporan Praktikum 1 EDA

Muhammad Dzaky Haidar  
5054251039

## 4. Visualisasi dan Interpretasi



Gambar 1. Kategori berita (kiri) dan hubungan panjang judul (kanan). Sumber: output notebook praktikum.

### a. Komposisi berita.

Consumer memuat 315 berita (19,55%), cyberlife 295 (18,31%), dan science 271 (16,82%). Ketiganya mencakup 54,69% sampel. Telecommunication memuat 127 berita (7,88%) dan fotoinet 111 (6,89%). Frekuensi tersebut menunjukkan komposisi publikasi yang terkumpul, bukan jumlah pembaca atau popularitas topik.

### b. Hubungan antaratribut.

Scatter plot menunjukkan kecenderungan positif antara jumlah kata dan karakter, dengan korelasi Pearson 0,68. Judul dengan lebih banyak kata cenderung lebih panjang. Hubungan ini wajar karena kedua ukuran berasal dari teks yang sama; panjang setiap kata yang berbeda menyebabkan titik tidak membentuk garis lurus sempurna.

### c. Waktu publikasi.

Batang tertinggi terlihat pada pukul 09.00 WIB. Publikasi lebih banyak terlihat sepanjang pukul 06.00-22.00 dibandingkan tengah malam hingga dini hari. Pola ini menggambarkan waktu penerbitan dalam sampel, bukan waktu akses pembaca.

### d. Perbandingan kategori.

Boxplot pada notebook memperlihatkan median panjang judul consumer sebesar 11 kata, cyberlife dan telecommunication 10 kata, serta science dan fotoinet 9 kata. Dengan demikian, judul consumer relatif lebih panjang di antara lima kategori terbanyak. Batas boxplot per kategori dapat berbeda dari batas IQR global pada bagian 3.

## 5. Kesimpulan dan Batasan

Scraping menghasilkan dataset yang memenuhi ukuran minimum dan memiliki kelengkapan tinggi. Judul umumnya berada di sekitar 10 kata atau 63 karakter. Consumer menjadi kategori terbanyak, publikasi memuncak pada jam 09.00 WIB, dan jumlah kata berkorelasi positif dengan jumlah karakter. Sampel mengikuti urutan indeks saat pengambilan, sehingga tidak mewakili seluruh arsip secara acak. Pergeseran halaman serta cakupan tanggal awal/akhir yang tidak penuh dapat memengaruhi distribusi. Untuk analisis lanjutan, jumlah outlier perlu dihitung dari CSV dengan batas IQR yang telah ditetapkan.