

Laporan Praktikum Preprocessing

Tugas Praktikum 2 – Data Mining

Muhammad Dzaky Haidar

5054251039

1. Pendahuluan

Laporan ini mendokumentasikan proses praproses (*preprocessing*) data yang dilakukan pada dataset *House Prices – Advanced Regression Techniques* dari Kaggle. Tujuan utama praproses adalah mempersiapkan data mentah agar layak digunakan untuk analisis lebih lanjut atau pelatihan model *machine learning*.

1.1. Dataset

Dataset yang digunakan adalah *train.csv* dari kompetisi Kaggle *House Prices – Advanced Regression Techniques*. Dataset ini berisi informasi harga rumah beserta berbagai atribut fisik dan kondisi rumah.

Sumber	https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques
Jumlah baris	1.460
Jumlah kolom	81 (termasuk target <code>SalePrice</code>)
Target variabel	<code>SalePrice</code> – harga jual rumah (USD)

1.2. Tujuan Praproses

1. Membersihkan data dari nilai yang hilang dan data tidak konsisten.
2. Mendeteksi dan menangani *outlier* pada atribut numerik.
3. Mentransformasi atribut melalui normalisasi dan *encoding*.
4. Mereduksi dimensi dengan analisis korelasi dan PCA.

2. Pembersihan Data

2.1. Identifikasi Nilai yang Hilang

Nilai yang hilang (*missing values*) diidentifikasi menggunakan `df.isnull().sum()` dan dikonversi ke persentase terhadap total baris. Dari 81 kolom, beberapa kolom memiliki proporsi *missing values* yang signifikan:

Kolom	Missing (%)	Keputusan
PoolQC	>99%	Dihapus (>50% missing)
MiscFeature	>96%	Dihapus (>50% missing)
Alley	>93%	Dihapus (>50% missing)
Fence	>80%	Dihapus (>50% missing)
FireplaceQu	47%	Diimputasi dengan modus
LotFrontage	17%	Diimputasi dengan median

Tabel 1: Kolom dengan missing values signifikan

2.2. Penanganan Nilai yang Hilang

Kolom dengan lebih dari **50% nilai hilang** dihapus karena tidak cukup representatif untuk dianalisis. Untuk kolom yang tersisa diterapkan strategi imputasi berikut:

- **Kolom numerik** – diimputasi dengan **median**, karena median lebih robust terhadap nilai ekstrem (*outlier*) dibandingkan mean.
- **Kolom kategoris** – diimputasi dengan **modus** (nilai paling sering muncul).

Setelah imputasi, tidak ada lagi nilai yang hilang dalam dataset.

3. Deteksi dan Penanganan Outlier

3.1. Deteksi dengan Boxplot

Outlier dideteksi menggunakan **boxplot** pada atribut numerik penting: `GrLivArea`, `TotalBsmstSF`, `LotArea`, `SalePrice`, `1stFlrSF`, dan `GarageArea`. Visualisasi menunjukkan sejumlah titik data yang jauh melewati batas *whisker* atas.

3.2. Keputusan: IQR Capping

Outlier tidak dihapus, melainkan disesuaikan menggunakan metode **IQR Capping** (*Winsorization*) dengan pertimbangan:

- Dataset relatif kecil (1.460 baris); penghapusan baris berisiko kehilangan informasi yang signifikan.
- IQR Capping membatasi nilai ke batas $Q_1 - 1.5 \times IQR$ dan $Q_3 + 1.5 \times IQR$ tanpa mengurangi jumlah baris.
- Distribusi keseluruhan data tetap terjaga.

4. Transformasi Data

4.1. Penanganan Skewness

Distribusi fitur numerik diperiksa menggunakan koefisien *skewness*. Fitur dengan $|\text{skewness}| \geq 1$ dianggap *highly skewed* dan ditransformasi menggunakan **log transformation** $\log(x + 1)$ agar distribusinya lebih mendekati normal.

4.2. Normalisasi (Min-Max Scaling)

Seluruh atribut numerik (kecuali **Id** dan **SalePrice**) dinormalisasi ke rentang $[0, 1]$ menggunakan:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Normalisasi dilakukan dengan **MinMaxScaler** dari *scikit-learn* agar tidak ada fitur yang mendominasi karena perbedaan skala.

4.3. Encoding Kategoris (One-Hot Encoding)

Atribut kategoris dikonversi ke format numerik menggunakan **one-hot encoding** (**pd.get_dummies** dengan **drop_first=True**). Pendekatan ini menghasilkan kolom biner per kategori dan menghindari asumsi urutan yang tidak berlaku.

5. Reduksi Dimensi

5.1. Analisis Korelasi

Analisis korelasi dilakukan untuk mengidentifikasi fitur redundan. Fitur dengan **korelasi antar-fitur** > 0.90 dihapus untuk menghindari multikolinearitas. *Heatmap* korelasi 15 fitur teratas terhadap **SalePrice** digunakan sebagai panduan.

5.2. Principal Component Analysis (PCA)

PCA diterapkan untuk mereduksi dimensi sambil mempertahankan **95% variansi** data. Jumlah komponen ditentukan secara otomatis. Grafik *Cumulative Explained Variance* digunakan untuk memvisualisasikan trade-off antara jumlah komponen dan variansi yang dipertahankan.

6. Ringkasan Dataset Akhir

Tahapan	Sebelum	Sesudah
Jumlah baris	1.460	1.460
Jumlah kolom (asli)	81	81
Kolom dihapus (>50% missing)	–	4 kolom
Missing values	Ada	0
Outlier	Ada	Di-cap (IQR)
Skewed features	Ada	Log-transformed
Kolom setelah one-hot encoding	77	>200
Kolom setelah reduksi korelasi	–	Berkurang
Komponen PCA (95% variansi)	–	n komponen

Tabel 2: Ringkasan transformasi dataset

Dataset akhir berisi komponen PCA (`PC1` , `PC2` , ..., `PCn`) beserta kolom target `SalePrice` , dan disimpan dalam file `5054251039_Muhammad_Dzaky_Haidar_Tugas_Preprocessing.csv` .

7. Kesimpulan

Proses praproses data telah berhasil dilakukan melalui lima tahap utama:

1. **Pembersihan data:** kolom dengan >50% *missing values* dihapus; sisanya diimputasi dengan median (numerik) dan modus (kategoris).
2. **Penanganan outlier:** IQR Capping diterapkan untuk mempertahankan jumlah baris sambil membatasi nilai ekstrem.
3. **Transformasi data:** log transformation untuk fitur *skewed*, normalisasi Min-Max, dan one-hot encoding untuk fitur kategoris.
4. **Reduksi korelasi:** fitur dengan korelasi antar-fitur > 0.90 dihapus.
5. **PCA:** dimensi dikurangi sambil mempertahankan 95% variansi data.

Dataset yang dihasilkan bersih, terskala, dan siap digunakan untuk pemodelan *machine learning* selanjutnya.