

Laporan Praktikum Preprocessing

Tugas Praktikum 2 – Data Mining

Muhammad Dzaky Haidar

5054251039

1. Pendahuluan

Praproses data (*data preprocessing*) merupakan tahap kritis sebelum data dapat digunakan untuk analisis atau pelatihan model *machine learning*. Data dunia nyata umumnya mengandung nilai yang hilang, *outlier*, skala yang tidak seragam, serta variabel kategoris yang perlu dikonversi ke representasi numerik. Laporan ini mendokumentasikan seluruh tahapan praproses yang dilakukan pada dataset *House Prices – Advanced Regression Techniques*.

1.1. Dataset

Sumber	Kaggle – House Prices: Advanced Regression Techniques
File	<code>train.csv</code>
Jumlah baris	1.460
Jumlah kolom	81 (38 numerik, 43 kategoris + target <code>SalePrice</code>)
Target variabel	<code>SalePrice</code> – harga jual rumah dalam USD

1.2. Tujuan Praproses

1. Membersihkan data dari nilai yang hilang dan data tidak konsisten.
2. Mendeteksi dan menangani *outlier* pada atribut numerik.
3. Mentransformasi atribut melalui normalisasi dan *encoding* kategoris.
4. Mereduksi dimensi dengan analisis korelasi dan PCA.


2. Pembersihan Data

2.1. Eksplorasi Awal

Eksplorasi awal dilakukan dengan `df.head()`, `df.shape`, dan `df.info()`. Hasil: dataset memiliki shape **(1460, 81)** dengan campuran tipe data numerik dan kategoris. Beberapa kolom langsung terlihat memiliki nilai `NaN` bahkan di 5 baris pertama (misalnya `Alley`, `MasVnrType`).

2.2. Identifikasi Nilai yang Hilang

`df.isnull().sum()` mengungkap **19 kolom** yang mengandung *missing values*. Visualisasi bar chart berikut menampilkan persentase nilai hilang per kolom.



Gambar 1: Persentase *missing values* per kolom (19 kolom, diurutkan descending)

2.3. Penanganan Nilai yang Hilang

Strategi yang diterapkan:


- **Hapus kolom** jika proporsi *missing* > 50%: `PoolQC` (>99%), `MiscFeature` (>96%), `Alley` (>93%), `Fence` (>80%).
- **Imputasi median** untuk kolom numerik yang tersisa.
- **Imputasi modus** untuk kolom kategoris yang tersisa.

Setelah imputasi, total *missing values* menjadi **0**.

3. Deteksi dan Penanganan Outlier

3.1. Deteksi dengan Boxplot

Boxplot diterapkan pada enam atribut numerik utama: `GrLivArea`, `TotalBsmtSF`, `LotArea`, `SalePrice`, `1stFlrSF`, dan `GarageArea`. Titik di luar batas *whisker* ($Q_1 - 1.5 \times \text{IQR}$ dan $Q_3 + 1.5 \times \text{IQR}$) dikategorikan sebagai *outlier*.



Gambar 2: Boxplot deteksi *outlier* pada 6 atribut numerik utama

3.2. Penanganan: IQR Capping

Outlier **tidak dihapus** melainkan di-*cap* (IQR Capping / Winsorization):

$$x_{\text{capped}} = \begin{cases} Q_1 - 1.5 \times \text{IQR} & \text{jika } x < Q_1 - 1.5 \times \text{IQR} \\ Q_3 + 1.5 \times \text{IQR} & \text{jika } x > Q_3 + 1.5 \times \text{IQR} \\ x & \text{selain itu} \end{cases}$$

Shape dataset setelah capping tetap **(1460, 81)** — tidak ada baris yang dihapus. Alasan: dataset berukuran kecil; menghapus baris berisiko kehilangan informasi yang signifikan, sementara capping cukup meredam pengaruh nilai ekstrem.

4. Transformasi Data

4.1. Penanganan Skewness

Koefisien skewness dihitung untuk seluruh fitur numerik. Dari hasil notebook, 10 fitur dengan skewness tertinggi setelah IQR capping adalah:

Fitur	Skewness
2ndFlrSF	0.800
BsmtUnfSF	0.797
BsmtFinSF1	0.740

Fitur	Skewness
HalfBath	0.676
1stFlrSF	0.664
GrLivArea	0.594
Fireplaces	0.585
OverallCond	0.579
BsmtFullBath	0.563
MasVnrArea	0.481

Dari hasil analisis, **tidak ada fitur** dengan $|s| \geq 1$ setelah IQR Capping, sehingga log transformation tidak diterapkan. Hal ini menunjukkan bahwa capping berhasil meredam distribusi ekstrem.

4.2. Normalisasi (Min-Max Scaling)

Seluruh atribut numerik (kecuali **Id** dan **SalePrice**) dinormalisasi ke $[0, 1]$:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Normalisasi dilakukan dengan **MinMaxScaler** dari *scikit-learn* agar tidak ada fitur yang mendominasi karena perbedaan skala.

4.3. Encoding Kategoris (One-Hot Encoding)

43 kolom kategoris dikonversi ke format numerik menggunakan `pd.get_dummies(..., drop_first=True)`


Setelah encoding, jumlah kolom bertambah dari 77 menjadi **246 kolom** sebelum reduksi korelasi.

5. Reduksi Dimensi

5.1. Analisis Korelasi

Analisis korelasi dilakukan dalam dua tahap.

1. Korelasi terhadap SalePrice: visualisasi heatmap 15 fitur teratas.

Gambar 3: Heatmap korelasi 15 fitur teratas terhadap **SalePrice**


2. Reduksi fitur redundan: fitur dengan korelasi antar-fitur > 0.90 dihapus. Dari notebook, kolom yang dihapus:

```
RoofStyle_Hip , Exterior2nd_CBlock , Exterior2nd_CmentBd , Exterior2nd_MetalSd ,
Exterior2nd_VinylSd , MasVnrType_Stone , ExterQual_TA , SaleCondition_Partial
```

Shape dataset setelah reduksi korelasi: **(1460, 238)**.

5.2. Principal Component Analysis (PCA)

PCA diterapkan dengan `n_components=0.95` (mempertahankan 95% variansi). Hasilnya: **99 komponen** PCA dipilih dari 237 fitur asli.



Gambar 4: Kurva *Cumulative Explained Variance* PCA — threshold 95% (garis merah)

Shape X setelah PCA: **(1460, 99)**.

6. Ringkasan Dataset Akhir

Tahapan	Sebelum	Sesudah
Jumlah baris	1.460	1.460
Jumlah kolom asli	81	81
Kolom dengan <i>missing values</i>	19	0 kolom missing
Kolom dihapus (>50% missing)	–	4 kolom
Total <i>missing values</i>	>0	0
<i>Outlier</i> ekstrem	Ada	Di-cap (IQR)
Fitur <i>highly skewed</i> ($ s \geq 1$)	Ada	0 (semua < 1)
Kolom numerik asli	38	38 (normalized)
Kolom kategoris	43	0 ($\rightarrow$ one-hot)
Kolom setelah one-hot encoding	–	246
Kolom setelah reduksi korelasi	–	238
Komponen PCA (95% variansi)	–	99 komponen
Shape dataset akhir	–	(1460, 100)

Tabel 1: Ringkasan lengkap transformasi dataset sepanjang pipeline praproses

Dataset akhir berisi 99 komponen PCA (**PC1 – PC99**) + kolom target **SalePrice** (total 100 kolom, 1.460 baris). File disimpan sebagai **5054251039_Muhammad_Dzaky_Haidar_Tugas_Preprocessing.csv**.

7. Kesimpulan

Pipeline praproses data telah berhasil dilaksanakan dengan hasil nyata berikut:

1. **Pembersihan data:** 19 kolom mengandung *missing values* — 4 kolom dengan $>50\%$ missing dihapus, sisanya diimputasi (median untuk numerik, modus untuk kategoris). Total missing values turun menjadi **0**.
2. **Penanganan outlier:** IQR Capping diterapkan pada seluruh fitur numerik. Jumlah baris tetap 1.460 tanpa ada data yang hilang.
3. **Transformasi:** Skewness tertinggi pasca-capping hanya 0.80 (di bawah threshold 1), sehingga log transformation tidak diperlukan. Normalisasi Min-Max dan one-hot encoding menghasilkan 246 fitur numerik.
4. **Reduksi korelasi:** 8 fitur redundan (korelasi > 0.90) dihapus, tersisa 238 fitur.
5. **PCA:** 238 fitur direduksi menjadi **99 komponen** yang menjelaskan 95% variansi data.

Dataset akhir (1.460×100) bersih, terskala, dan siap digunakan untuk pemodelan *machine learning* seperti regresi atau *ensemble methods*.